Sistema de web scraping e análise de dados do e-commerce

Francisco Eudázio Suriano da Silva Júnior[1]*; José Guilherme Martins dos Santos[2]

[1] Bernoulli Educação. Engenheiro de Dados. Rua Alwin Otto, 512 – Centenário; 89256-730, Jaraguá do Sul, Santa Catarina, Brasil
[2] Nottus Meteorologia. Especialista em Ciência de Dados e Análise. Av. das Nações Unidas, 11.541, 10° Andar - Brooklin; 04578-907, São Paulo, São Paulo, Brasil
*autor correspondente: jrsuri@outlook.com

Sistema de web scraping e análise de dados do e-commerce

Resumo

Neste trabalho foi desenvolvido um sistema completo de coleta, armazenamento e visualização de dados de lojas de e-commerce no Brasil. A coleta de dados foi realizada por meio de técnicas de web scraping, permitindo a extração automatizada de informações sobre produtos, preços e disponibilidade. Os dados capturados foram armazenados em um banco de dados SQL, garantindo a organização e acessibilidade para consultas futuras. Para a etapa de visualização e análise dos dados, foi utilizado o Power BI. Assim, o projeto busca demonstrar um ciclo completo de tratamento de dados, desde a aquisição até a sua análise final em um painel de BI.

Palavras-chave: ETL, automação, inteligência de negócios, análise de dados, visualização de dados.

Introdução

Com o crescimento exponencial do volume de dados disponíveis online, a coleta automatizada de informações tornou-se essencial para projetos de ciência de dados. Nesse contexto, o *web scraping* (raspagem de dados) tem sido amplamente utilizado como uma abordagem eficiente para extrair dados não estruturados diretamente de páginas da web, transformando-os em formatos estruturados úteis para análise e tomada de decisão (Farias *et al*., 2021).

Essa técnica integra-se à primeira etapa de projetos de ciência de dados, viabilizando a coleta em larga escala de informações sobre produtos, preços e outros atributos expostos em ambientes digitais. A automação desse processo reduz significativamente o tempo e o esforço manual, ao mesmo tempo em que proporciona maior abrangência e frequência de atualização das informações (Grant Thornton Brasil, 2024). Uma vez coletados, os dados são normalmente armazenados em bases estruturadas, o que permite sua posterior visualização, análise estatística e até mesmo uso em modelos de aprendizado de máquina.

No setor de comércio eletrônico, o *web scraping* tem sido aplicado como uma ferramenta estratégica para monitoramento de mercado, possibilitando o acompanhamento de preços, avaliações de consumidores e lançamentos de produtos de forma sistemática. Estudos recentes apontam que essa técnica pode gerar inteligência competitiva ao fornecer dados em tempo real sobre o comportamento da concorrência e preferências do consumidor (Sridhar *et al*., 2024).

O mercado brasileiro de *e-commerce*, por sua vez, apresenta um cenário propício à aplicação dessa abordagem, especialmente no segmento de hardware de computador, que é caracterizado por alta competitividade, variedade de produtos e constante oscilação de preços. De acordo com o Ministério do Desenvolvimento, Indústria, Comércio e Serviços

(MDIC), o setor movimentou cerca de R$ 196 bilhões em 2023, o que evidencia sua relevância econômica e o potencial analítico de seus dados (Ministério do Desenvolvimento, Indústria, Comércio e Serviços [MDIC], 2024).

Neste trabalho, foi explorado o uso técnico do *web scraping* aplicado ao *e-commerce* nacional de *hardware*, demonstrando todas as etapas de um projeto de ciência de dados, desde a extração automatizada até o armazenamento e visualização das informações coletadas.

O objetivo deste estudo foi desenvolver um sistema automatizado capaz de realizar a coleta de dados de sites de *e-commerce*, armazená-los de forma estruturada em um banco de dados SQL e disponibilizá-los para visualização e análise em um painel no Power BI. Ao final da pesquisa, espera-se demonstrar a eficiência do sistema no monitoramento contínuo de informações de produtos, como preços e disponibilidade, proporcionando uma ferramenta prática para suportar a tomada de decisão com base em dados.

Metodologia

Este estudo utiliza uma abordagem de pesquisa experimental, implementando um sistema automatizado de coleta, armazenamento e análise de dados provenientes de lojas de comércio eletrônico brasileiras. A pesquisa se estrutura em três etapas principais: coleta de dados, armazenamento e visualização.

Coleta de dados

A coleta de dados foi realizada utilizando técnicas de *web scraping*, implementadas em um *script* escrito em Python. Este *script* acessa automaticamente algumas lojas de *e-commerce*, com o objetivo de extrair informações sobre produtos.

O script utiliza paralelismo, através da biblioteca *concurrent.futures* do Python. O acesso automatizado às páginas é feito respeitando intervalos de acesso aleatórios entre 2 a 4 segundos, para evitar sobrecarregar os sites. Os produtos são definidos a partir de um dicionário de entradas configurado no início do *script*, categorizados em diferentes tipos. Para este trabalho, optou-se por pesquisar produtos relacionados a *hardware* de computadores de mesa (*desktops*), como processadores, placas de vídeo, placas-mãe, memórias e SSDs.

A busca por produtos foi personalizada de acordo com as URLs e parâmetros de pesquisa de cada loja. Para cada produto e site, o *script* executa as seguintes etapas:

1. Navega automaticamente nas páginas, utilizando a biblioteca Selenium configurada no modo "*headless*" (sem interface gráfica), para maior eficiência e escalabilidade.

2. Extrai os nomes dos produtos, preços e URLs correspondentes utilizando a biblioteca BeautifulSoup, com base na estrutura HTML específica de cada site.
3. Valida e filtra os dados extraídos para evitar inconsistências, incluindo:
    a. Ignorar produtos com palavras-chave indesejadas, como "notebook" ou "cabo".
    b. Verificar compatibilidades específicas, como suporte a DDR5 para placas-mãe e latência para memórias RAM.
4. Organiza os dados em listas estruturadas.
5. Após a coleta, realiza ajustes nos dados, como:
    a. Corrigir inconsistências nos nomes dos produtos, padronizando entradas como "RTX 4060 Ti" e "Ryzen 7 7700X" de acordo com o produto buscado e o nome obtido.
    b. Identificar categorias específicas, como "PC Gamer" e "Kit Upgrade", com base em padrões nos nomes dos produtos.

Armazenamento dos dados

Os dados coletados são inicialmente armazenados em um arquivo do Excel localizado em um diretório especificado no sistema, como *backup*. Após isso, os dados são consolidados, eliminando duplicatas e ordenando os registros por produto, data de acesso e preço. Além do armazenamento local, o script integra os dados com um banco de dados MySQL, criado e mantido *on-premises* (não em nuvem). O processo utiliza a biblioteca SQLAlchemy e envolve:

1. Consultar os dados já existentes no banco para o dia atual, garantindo que não sejam inseridos registros duplicados.
2. Inserir os novos dados no banco após a remoção prévia dos registros do dia.
3. Organizar os registros no banco para facilitar consultas futuras e análises históricas.

Os dados são armazenados no banco em uma tabela chamada *hardware_price_history*.

Resultados

Os dados coletados e armazenados foram integrados a um painel no Power BI, que lê a tabela *hardware_price_history* diretamente do banco de dados MySQL. O dashboard foi configurado para exibir informações como:

1. Gráfico de distribuição de preços por loja: mostram a variação de preços entre diferentes lojas, permitindo identificar quais lojas apresentam os melhores preços ou as maiores flutuações.

2. Gráfico de distribuição de preços por produto: apresentam a dispersão de preços para cada categoria de produto, facilitando a análise de tendências e comparações entre produtos.
3. Quantidade de ofertas por loja: um gráfico de rosca detalha a proporção de produtos encontrados em cada loja, possibilitando a identificação de sites com maior ou menor variedade.
4. Tabela de menores preços: uma tabela destaca os produtos com os menores preços encontrados, incluindo o nome, o preço, o site e o link direto para o produto.
5. Filtros interativos (*slicers*): permitem a segmentação por tipo de produto, intervalo de datas e outras variáveis, fornecendo flexibilidade na análise.

A visualização é baseada na tabela *hardware_price_history* e utiliza uma tabela dimensão de data (dCalendario) para agrupar os dados por períodos (dias, meses ou anos). Isso possibilita o acompanhamento histórico das variações de preço e disponibilidade de produtos. As análises ajudam a identificar padrões de mercado e podem servir como base para tomadas de decisões.

Um exemplo do *dashboard* desenvolvido é mostrado na Figura 1.

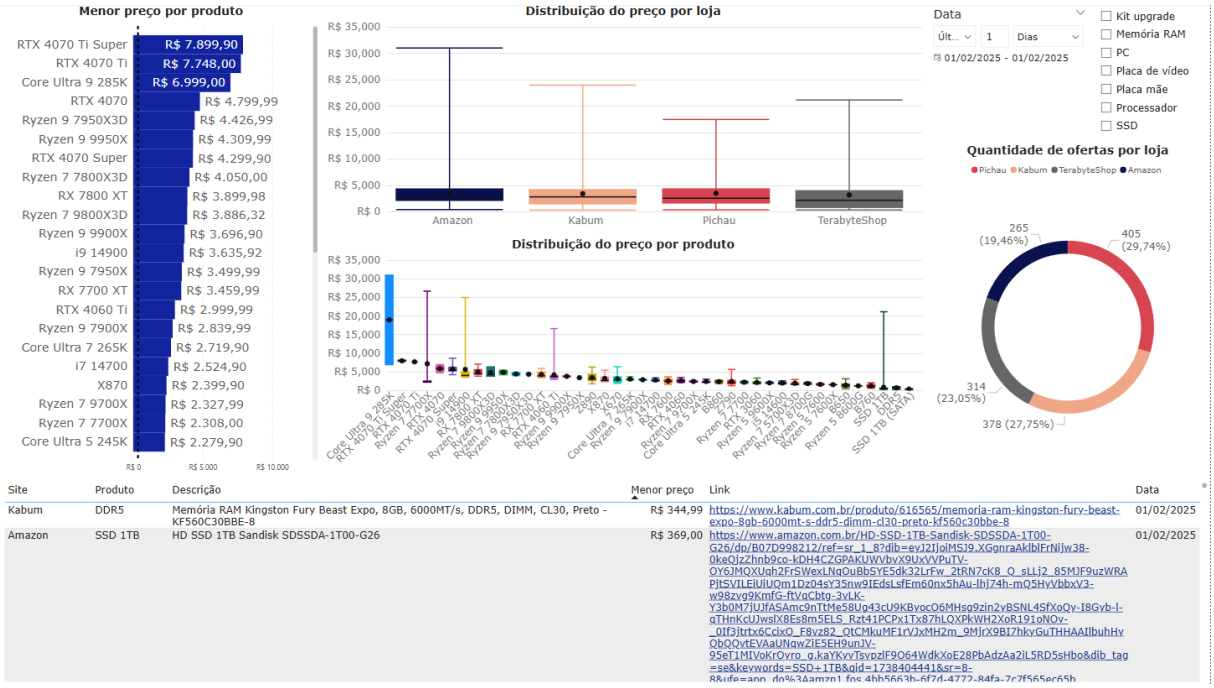

Figura 1. Painel desenvolvido no Power BI com os dados coletados
Fonte: Resultados originais da pesquisa

Na data de escrita deste documento (21 de abril de 2025) a base de dados contava com 631047 registros, coletados ao longo de 451 dias, correspondendo a uma média de 1399 registros por data.

A base de dados, o código completo do *script* e o *dashboard* desenvolvido no Power BI foram disponibilizados no Github <https://github.com/jrsuri/ecommerce-webscraper>.

Considerações Finais

O estudo apresentou o desenvolvimento de um sistema automatizado para coleta, armazenamento e visualização de dados do comércio eletrônico, alcançando os objetivos estabelecidos. O sistema demonstrou sua eficácia ao permitir o monitoramento contínuo de preços e disponibilidade de produtos em diversas plataformas de comércio eletrônico, fornecendo dados consolidados e acessíveis para análises.

A integração com o Power BI destacou o potencial do sistema em gerar *insights* por meio de painéis interativos, como a identificação de padrões de preços, distribuição de ofertas e comportamento de mercado. Esses resultados indicam que a ferramenta pode auxiliar na tomada de decisão, especialmente quando se depende do acompanhamento dinâmico de preços de produtos.

Além disso, o projeto evidenciou a escalabilidade e a replicabilidade do sistema. Sua arquitetura modular permite adaptações para diferentes cenários, incluindo novos tipos de produtos, fontes de dados e volumes maiores de informações. A pesquisa, portanto, contribui para o campo da análise de dados aplicada ao comércio eletrônico, oferecendo um modelo prático e eficiente que pode ser replicado em outros contextos comerciais.

Referências

Farias, M.T.; Angeluci, A.; Passarelli, B. 2021. Web scraping e ciência de dados na pesquisa aplicada em comunicação: um estudo sobre avaliações online. Revista Observatório 7(3): 1–21.

Grant Thornton Brasil. 2024. Raspagem de dados: entenda a nova prioridade da ANPD e seus efeitos. Grant Thornton Insights. Disponível em: <https://www.grantthornton.com.br/insights/artigos-e-publicacoes/raspagem-de-dados-entenda-a-nova-prioridade-da-anpd-e-seus-efeitos/>. Acesso em: 21 abr. 2025.

Sridhar, S.G.; Sathwika, S.; Reddy, K.S. 2024. Webscraping for e-commerce website. International Research Journal of Modernization in Engineering, Technology and Science 6(5): 457–461.

Ministério do Desenvolvimento, Indústria, Comércio e Serviços [MDIC]. 2024. E-commerce no Brasil cresce 4% e alcança R$ 196 bi em 2023. Brasília, DF, Brasil. Disponível em: <https://www.gov.br/mdic/pt-br/assuntos/noticias/2024/setembro/e-commerce-no-brasil-cresce-4-e-alcanca-r-196-bi-em-2023>. Acesso em: 21 abr. 2025.